



Universidad de San Andrés

Big Data

Trabajo Práctico 1



Otoño 2026

Integrantes:

Constanza María Efkhanian
Julián Fabrizio Notario
María Florencia Pascale

Fecha de entrega: 27 de marzo de 2026

Parte I: Familiarizándonos con la base EPH y limpieza

1.

De acuerdo con el INDEC, a las personas informales se las registra a través de la EPH (Encuesta Permanente de Hogares). A su vez, dentro de la sección de "Ocupación Principal de los Asalariados", se encuentran preguntas como: ¿Por ese trabajo tiene descuento jubilatorio?; ¿Aporta por sí mismo a algún sistema jubilatorio?. Si la respuesta a cualquiera de estas dos preguntas es negativa, esto implica que el empleador no realiza aportes al sistema, por lo que el empleo no está registrado. 

Por otro lado, para trabajadores independientes, al no haber empleador, se utilizan distintos métodos para determinar la condición de formalidad/informalidad laboral. En estos casos, dentro de la sección "Ocupación Principal de los trabajadores Independientes" preguntas que indiquen que no hacen ningún tipo de aporte, que el tipo de negocio sea una sociedad convenida de palabra, o que el negocio no pueda emitir facturas son fuertes indicadores de que el trabajo es informal.

2.

a. La región elegida fue la del Gran Buenos Aires (GBA). El código se realizó en el archivo de Notebook.

b. Realizado en el archivo de Notebook.

c. Para el proceso de limpieza de los datos, nos basamos en el diccionario de variables de la EPH. A partir de esto, reemplazamos todos los "-1" dentro de la variable de edad (CH06) por N/As, puesto que no representan una edad real. Además, para las variables de "estado civil" y "cobertura médica", convertimos el valor "No sabe/No responde (9)" a N/As. Por otro lado, para la variable de "sector del empleador" cambiamos los "no aplica" y "Ns/Nr" (0 y 9 respectivamente) por N/As. Lo mismo se hizo para los valores 0 y 99 de la variable de "tamaño del establecimiento (PP04A)".

Finalmente, los "No respuesta (-9)" de las variables de ingreso (P21 e IPCF) se convirtieron a N/As. Notar que variables como PP07H, PP04A y P21 contienen N/As generadas estructuralmente. Un ejemplo de esto es que, si alguien está empleado, en la variable de tiempo desempleado no aplica (N/A).

d. El *heatmap* muestra el porcentaje de valores faltantes (NaN) para cada variable seleccionada previamente, comparando los años 2005 y 2025 (n=9.420 y n=2.709, respectivamente). En la mayoría de las variables no se presentan valores faltantes en ninguno de los dos años. Esto indica una buena calidad general de los datos. No obstante, se



observan ausencias considerables en las variables "PP04A" (56,6% en 2005 y 51,5% en 2025) y "EMPLEO" (100% en 2005 y 51,5% en 2025). Cabe aclarar que la razón por la que la variable de "EMPLEO" tenga un 100% de *missing values* en el 2005 es debido a que esta variable no existía para ese año. Además, en el año 2025 también aparecen valores faltantes en PP07H (51,5%) y P21 (15,5%).

Porcentaje (%) de missing values de cada variable, por año




Figure 1: *Heatmap*.

Parte II: Primer Análisis Exploratorio

3.




Figure 2: *Gráfico de barras: Composición por sexo 2005 y 2025 para la región de GBA.*

Como se puede ver, en ambos casos (2005 y 2025) la región de GBA (Gran Buenos Aires) está mayoritariamente compuesta por mujeres, aunque se puede observar que la brecha entre hombres y mujeres es menor para los datos de 2025.

4. Debajo, se encuentra la matriz de correlación de las variables especificadas para los años 2005 y 2025.




Figure 3: *Matriz de correlación.*

Como podemos ver, la relación más fuerte entre las variables es la de "Edad" y "Jubilado". Esto tiene sentido, dado que la condición de jubilación está directamente ligada a la edad. Otra relación fuerte que se puede observar es, nuevamente, entre la variable de "Jubilado" y "Viudo", y entre esta última y "Edad". Otra vez, esto tiene sentido debido a que las personas jubiladas tienden a ser mayores de 65 años, por lo que sería lógico que una parte considerable de estos fuera viudos/as. Otra relación fuerte y positiva se encuentra entre "Ocupado" y "Nivel educativo", lo que puede indicar que una mayor educación se asocia con una mayor inserción laboral. 

Por otro lado, las correlaciones negativas más notorias que se encuentran en esta matriz se dan entre "Jubilado" y "Ocupado", entre "Separado/Divorciado" y "Unión/Casado", y esta última también con "Viudo". Esto indica que estas categorías tienden a excluirse entre sí.

De todas maneras, en general, las correlaciones son de magnitud moderada o baja, lo que sugiere que ninguna variable explica completamente a otra. 

Parte III: Conociendo el mercado laboral

5. En total, 11 personas no respondieron cuál es su condición de actividad (ESTADO = 0).

6. Realizado en el archivo de Notebook.

7. Realizado en el archivo de Notebook. 

8. Comparamos la variable "EMPLEO" con la variable "Informal" creada en 2025. Nos pareció interesante debido a que nos permite ver qué tan bien captura nuestro indicador manual la informalidad real medida por el INDEC. 

9. A continuación, se encuentra la tabla de estadísticas descriptivas, así como también los gráficos exploratorios realizados.

Table 1: *Estadísticas descriptivas por condición de informalidad — GBA.*

Año	Condición	N	Edad prom.	Ing. ocup. ppal.	Ing. p.c.f.	% Mujeres	Nivel educ.
2005	Informal	1412	37.3	495.1	479.4	49.4	3.3
	Formal	2676	41.3	1085.4	783.0	38.3	4.0
2025	Informal	365	39.0	535.400	260.026	48.8	3.9
	Formal	948	43.9	1.124.700	538.841	42.5	4.3




Figure 4: *Proporción de informalidad por grupo etario.*




Figure 5: *Proporción de informalidad por nivel educativo.*

En primer lugar, la tabla 1 muestra estadística descriptiva acerca de las condiciones (formal/informal) de los trabajadores en los años 2005 y 2025. Por un lado, podemos observar una reducción en el tamaño muestral (N) entre ambos años. En cuanto a los ingresos, tanto el ingreso ocupacional principal como el ingreso per cápita familiar (Ing. ocup. ppal. y Ing. p.c.f., respectivamente) crecieron notablemente entre 2005 y 2025. Esto probablemente tenga que ver con el gran aumento en la inflación que padeció la Argentina durante este período. Además, podemos notar que la brecha de ingresos entre formales e informales se mantuvo bastante marcada en ambos años analizados. Respecto a la edad promedio, los trabajadores formales fueron levemente mayores que los informales en ambos

períodos. Cabe agregar que la proporción de mujeres fue mayor entre los informales que entre los formales, aunque esta brecha se redujo en 2025. Por último, el nivel educativo promedio fue similar entre grupos, pero levemente superior en los formales (lo cual tiene sentido, teniendo en cuenta los resultados discutidos en la matriz de correlación).

En segundo lugar, en la figura 4 se puede apreciar la proporción de informalidad laboral por grupo etario para el año 2005 y 2025. Como se puede ver, el rango etario donde se encuentran la mayor cantidad de informales es en el más joven (15-24 años). Esto posiblemente tiene que ver con que las personas que suelen tener trabajos dentro de este rango de edades son aquellos de niveles socioeconómicos más bajos, los cuales son más propensos a caer en la informalidad. A partir de ahí, se observa una caída con los años del nivel de informalidad (y también se puede ver cómo la proporción de informalidad es menor en todos los grupos etarios para 2025 que para 2005). Algo interesante que vale la pena mencionar es que se puede ver un leve ascenso en el último rango de edad (65+), lo cual se puede deber (o estar relacionado) con las condiciones precarias de las jubilaciones. Este hecho puede incentivar a personas de este grupo etario a buscar trabajos, los cuales tiendan a ser más informales que formales.

Finalmente, en la figura 5 se observa la proporción de informalidad por nivel educativo. En este gráfico, se puede ver claramente una relación inversa entre el nivel educativo y la informalidad. Es decir, a mayor educación, menor proporción de trabajadores informales. Este resultado es consistente con la literatura existente.

Parte IV: Herramientas de IA y reflexión final

A continuación, se encuentra el apéndice que explicita el uso de IA para realizar el trabajo.

1. Apéndice

Aclaración: La única herramienta de IA utilizada fue Claude.




Figure 6: *Captura 1.*



Figure 7: *Captura 2.*



Figure 8: *Captura 3.*




Figure 9: *Captura 4.*




Figure 10: *Captura 5.*



Figure 11: *Captura 6.*

Dame funciones específicas que necesitaria saber para poder hacer el el punto 9.

Para el punto 9 específicamente necesitás saber:

Tabla de estadísticas:

- `df.groupby()` — agrupar por una variable
- `df['col'].mean()` — promedio
- `pd.DataFrame()` — crear tabla desde cero
- `df.set_index()` — definir índice de la tabla

Gráficos:

- `pd.cut()` — convertir variable continua (edad) en grupos/categorías
- `df.groupby()['col'].mean()` — proporción de informales por grupo
- `ax.bar()` — gráfico de barras agrupadas
- `ax.set_xticks()` / `ax.set_xticklabels()` — personalizar eje x
- `.reindex()` — reordenar categorías en un orden específico

La más importante que no habrían usado antes es `pd.cut()`, que hace esto:

```
python
# Convierte edad continua en grupos
pd.cut(df['CH06'],
       bins=[14, 24, 34, 44], # límites de los grupos
       labels=['15-24', '25-34', '35-44']) # nombres
```

Sin `pd.cut()` no podés hacer el gráfico por grupo etario.

Figure 12: *Captura 7.*

2. Reflexión

La IA nos fue útil con cuestiones de funciones específicas (es decir, nomenclaturas) y de sintáxis. A lo que nos referimos con esto es que, cuando no teníamos una idea muy clara de qué tipo de comando utilizar para realizar lo que teníamos en mente, la IA fue extremadamente útil para guiarnos en la dirección correcta. También nos ayudó con cuestiones de errores técnicos en el código para que pudiéramos corregirlos, y para poder entender cuáles eran los errores que estábamos cometiendo, todo a fin de poder crecer y aprender de estos. En cambio, para cuestiones de interpretación de gráficos/resultados, no sentimos que nos fuera de utilidad hacer uso de la IA.

3. Realización

En total, nos llevó una cantidad considerable de tiempo realizar este trabajo. Aproximadamente, diríamos que nos llevó 19 horas. Más que nada, como era de esperar, nos llevó mucho tiempo la parte I del TP.