



Universidad de
San Andrés

Big Data

Trabajo Práctico 2

Otoño 2026

Integrantes:

Constanza María Efkhanian
Julián Fabrizio Notario
María Florencia Pascale

Fecha de entrega: 10 de abril de 2026

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final

1. A continuación, se encuentra el histograma de la variable edad y la distribución de kernel para los trabajadores formales e informales.




Figure 1: *Histograma de edad y distribución kernel.*

En primer lugar, podemos observar que la población de la región elegida (GBA) se concentra mayoritariamente en los rangos de edad joven y adulta activa. Luego, se puede apreciar una caída progresiva hacia las edades más avanzadas. Esto quiere decir que el grupo predominante en la base de la EPH es el de aquellas personas en edad de trabajar.

Por otro lado, al comparar las distribuciones, se puede ver que la curva de los trabajadores informales está un tanto desplazada hacia la izquierda en comparación con la de los formales. Esto significa que las personas que se encuentran en un contexto de informalidad suelen ser más jóvenes, lo cual se puede deber a que enfrentan mayores barreras de entrada al mercado laboral formal.

2. A continuación, se presenta la tabla con la estadística descriptiva:

Table 1: *Años de educación (estadística descriptiva).*

Estadístico	Valor
Media	10.04
Desv. Estándar	4.70
Mínimo	0.00
Mediana	12.00
Máximo	26.00

Como se puede ver, en promedio, los años de educación que presentan los encuestados son 10 aproximadamente. Esto es equivalente a no haber terminado el secundario. Además, la mediana es de 12 años, lo que corresponde a la finalización del nivel secundario. Esto sugiere que la distribución está sesgada hacia la izquierda, es decir, la media está por debajo de la mediana. Por último, podemos ver que el mínimo de años de educación es de 0 años, y el máximo es de 26. Esto implica que hay una gran diversidad en la base de datos respecto al nivel educativo que poseen los individuos (personas sin ningún nivel educativo formal, como también individuos con estudios de posgrado completos).

3. Debajo, se encuentra el histograma que describe el ingreso total familiar y la distribución de kernel de ingresos por tipo de empleo.




Figure 2: *Histograma de ingreso total familiar y distribución kernel de condición laboral.*

Para empezar, en el histograma de ingreso total familiar podemos ver que la distribución está fuertemente sesgada hacia la derecha, lo que significa que la mayoría de las familias de la muestra se encuentran concentradas en los niveles de ingresos más bajos.

Por otro lado, tenemos la distribución kernel de ingresos dependiendo de la condición laboral. En este gráfico, se puede ver cómo los hogares con trabajadores informales tienen su densidad concentrada en niveles de ingreso más bajos y con un pico más pronunciado, mientras que la distribución de los formales es más achatada y se desplaza hacia la derecha. Esto indica que los ingresos familiares de aquellos en condición laboral formal son, en promedio, superiores a aquellos que se encuentran en la informalidad. Por lo tanto, parece ser que la formalidad laboral está asociada a un mayor ingreso familiar total, lo cual es consistente con la literatura existente.

4. Lo siguiente es la tabla de estadísticas descriptivas de las horas trabajadas:

Table 2: *Horas trabajadas (estadística descriptiva).*

Estadístico	Valor
Media	33.75
Desv. Est.	24.10
Mínimo	0.00
Mediana	40.00
Máximo	122.00

Podemos observar aquí que las horas trabajadas son, en promedio, 34 horas semanales, lo cual es un tanto inferior a la mediana de 40 horas semanales (que es la más frecuente entre los jefes de hogar). Por otro lado, la desviación estándar es un tanto elevada. Esto indica que hay una gran heterogeneidad en las horas trabajadas entre los encuestados. Con relación a esto, podemos observar que el mínimo de horas trabajadas es de 0 horas (es decir, que en la semana en la que fueron entrevistados, ciertos individuos no trabajaron). En cambio, el máximo es 122 horas semanales trabajadas, lo cual es un valor extremo, pero se encuentra dentro de los límites posibles.

5. Debajo se encuentra la tabla que resume la base de datos de la región elegida (GBA).

Table 3: *Resumen de la base final para la región GBA.*

	2005	2025	Total
Cantidad de observaciones	9420	7447	16867
Cantidad de observaciones con NAs en "Informal"	5332	3910	9242
Cantidad de Informales	1412	925	2337
Cantidad de Formales	2676	2612	5288
Cantidad de variables limpias y homogeneizadas	247	247	247

Como breve comentario, podemos ver que la cantidad de observaciones cayó en 2025 respecto de 2005. Además, es interesante la cantidad de valores faltantes para la sección de informalidad en ambos años, lo que puede deberse a una falta de información para clasificarlos. Por último, mientras que en 2005 los informales representaban un porcentaje considerable del total de ocupados clasificados (34,5%), en 2025 esta proporción descendió de manera notable (26,2%).

Parte II: Métodos No Supervisados

1. A continuación, se encuentra la matriz de correlación para la región de GBA:

Table 4: *Matriz de Correlación.*

	Edad	Edad ²	Educ.	ITF	Hogar	Horas
Edad	1.00					
Edad ²	0.96	1.00				
Educación	0.13	0.08	1.00			
ITF	-0.02	-0.04	0.08	1.00		
Hogar	-0.41	-0.40	-0.10	0.06	1.00	
Horas	0.18	0.04	0.17	0.09	-0.13	1.00

Existe una fuerte relación esperable entre "Edad" y "Edad²". Se destaca la correlación negativa entre estas y "Personas en el Hogar", sugiriendo que el tamaño del hogar disminuye con la edad (posiblemente por la emancipación de los hijos).

Por otro lado, la débil relación del "ITF" con "Educación" y "Horas Trabajadas" podría indicar una falta de linealidad entre estas variables. Finalmente, se observa una leve asociación positiva entre "Horas Trabajadas" y "Educación", señalando jornadas algo más extensas en niveles educativos superiores.

PCA

2. Lo que sigue es el gráfico de dispersión del primer y segundo componente de PCA.




Figure 3: *Gráfico de dispersión de PCA.*

Como se puede ver, los dos componentes juntos explican el 58.3% de la varianza (37,5% el primero y 20,8% el segundo), lo cual sugiere que el gráfico es una representación bastante fiel de la estructura de la base original. Por otro lado, la gran mayoría de las observaciones se agrupan en un tipo de nube densa en los valores bajos del componente 2, pero se dispersan ampliamente a lo largo del eje del componente 1. Esto indica que el primer componente es el principal diferenciador entre los individuos de la muestra de GBA. Como último comentario, podemos observar outliers con valores muy altos en el componente 2, que representan individuos con características extremas, pero la mayoría de las observaciones están concentradas cerca del origen.

3. En este inciso se puede encontrar, a continuación, el gráfico de *loadings* de PCA.




Figure 4: *Gráfico loadings de PCA.*

En este caso, se puede ver que el componente 1 está fuertemente dominado tanto por la variable "Edad" como por "Edad²" (para la derecha), y por "Personas del Hogar" (para la izquierda). Esto significa que el primer componente ubica a la derecha a las personas de mayor edad que viven en hogares más pequeños, mientras que a la izquierda están las personas más jóvenes que conviven con más personas (hay una relación negativa entre estos dos).

Para el caso del componente 2, en cambio, puede ver que las variables que más pesan son "Horas trabajadas", "Años de Educación" e "ITF". Por lo tanto, aquí se puede apreciar que individuos con mayor educación, que trabajan más horas y perciben mayores ingresos tienen *scores* más altos.

4. Debajo, se encuentra la proporción de la varianza explicada para cada componente.




Figure 5: *Gráfico varianza explicada para cada componente.*

En estos dos gráficos, se puede observar que el componente 1 explica la mayor parte de la varianza total de las variables elegidas. Además, podemos ver que el componente 2 es el segundo que más explica esta varianza total. A partir de ahí, notamos que la ganancia por agregar un componente más es significativamente menor (el método *elbow*). Además, en el segundo gráfico en específico, podemos ver que, al combinar únicamente los dos primeros componentes principales, logramos explicar casi un 60% de la variabilidad total de las seis variables originales, que es lo que habíamos observado previamente en el inciso 2.

Clústers

5. a. El siguiente gráfico muestra la aplicación de k-means con $k = 2$, $k = 4$ y $k = 10$.




Figure 6: *K-means con edad e ingreso familiar en GBA (EPH 2005 y 2025).*

Para empezar, puede afirmarse que, en los tres paneles, existe un patrón común: la gran mayoría de los individuos se concentra en la franja inferior del gráfico, con una pequeña

cantidad de outliers de ingresos muy elevados. Como se observa, el algoritmo con $k = 2$ no logra separar correctamente a los trabajadores formales e informales. En primer lugar, porque los clusters están dominados por outliers de ingresos. En segundo lugar, porque la formalidad no se refleja linealmente en las variables de edad e ITF; trabajadores formales e informales pueden tener edades y niveles de ingreso familiar similares. Por último, k-means es sensible a la escala y los outliers. Por consiguiente, la gran dispersión en el eje vertical hace que la geometría de los clusters quede determinada por los valores extremos y no por la estructura subyacente de formalidad e informalidad.

b. El siguiente gráfico muestra el método *Elbow* para la determinación de clusters:




Figure 7: *K-means con edad e ingreso familiar (método Elbow).*

A primera vista, pareciera que el número ideal de clusters es de 4, puesto que allí es donde la pendiente cambia de manera más visible. Sin embargo, esta cantidad de clusters no refleja la dimensión formal e informal; si este fuera el caso, el mejor número de clusters sería de 2. En cambio, lo que nos proporciona el gráfico es una intuición sobre distintos perfiles de edad e ingreso de trabajadores. Es decir, hay 4 grandes maneras de agrupar a los empleados según su edad e ingreso.

6. Un *dendograma* es un diagrama con forma de árbol invertido que muestra los grupos que se forman al crear clusters de observaciones en cada paso y sus niveles de similitud. La imagen que se encuentra debajo muestra el dendograma realizado para este ejercicio:




Figure 8: *Dendrograma - Clustering jerárquico con método completo.*

7. El siguiente gráfico muestra el cluster k-moda realizado con $k=2$ para las condiciones laborales y las de actividad:




Figure 9: *Cluster k-moda con $k=2$. GBA EPH 2005 y 2005.*

A nuestro criterio, el algoritmo k-moda con $k=2$ no logra captar la condición de formalidad, pero sí la de actividad laboral. Como se observa, formales e informales coexisten en los clusters 0 y 1. En este sentido, lo que diferencia a ambos grupos es el hecho de estar activamente trabajando (cluster 0) o no (cluster 1).

Parte III: Herramientas de IA y reflexión final

1. Apéndice

A continuación, se encuentra especificada la utilización de IA para este trabajo. Vale la pena aclarar que utilizamos únicamente como herramienta de IA a Claude.

Consulta 1:




Figure 10: *Captura 1.*

Variables con valores a limpiar (comparando ambos diccionarios):			
Variable	Código problemático	Motivo	¿En cuál base?
CH06	-1	Edad inválida	Ambas
CH07	9	Ns/Nr	Ambas
CH08	9	Ns/Nr (123 es válido)	Ambas
NIVEL_ED	9	Ns/Nr	Ambas
CAT_OCUP	9	Ns/Nr	Ambas
PP04A	0, 9	No aplica / Ns/Nr	Ambas
PP07H	—	Solo 1/2, sin problemáticos	Ambas
P21	-9	No respuesta de ingresos	2025
IPCF	-9	No respuesta de ingresos	2025
PP06C , PP06D	-7, -8, -9	No tenía ocupación / sin ingresos / no respuesta	2025
EMPLEO	9	Ns/Nr	2025 (en 2005 es todo NaN)

↓

Un dato importante que surge del diccionario de 2025: la regla general es que **9, 99, 999, 9999 = Ns/Nr** salvo indicación contraria, y **-9 = no respuesta en variables de ingreso**. En 2005 los negativos en ingresos eran **-7** y **-8** (solo para PP06C/D), no **-9**.

Figure 11: *Captura 2.*

```
python

# =====
# LIMPIEZA DE CÓDIGOS SIN SENTIDO → NaN
# Basada en los diccionarios EPH 2005 y 2025
# =====

# --- CH06: edad inválida ---
df_2005['CH06'] = df_2005['CH06'].replace(-1, np.nan)
df_2025['CH06'] = df_2025['CH06'].replace(-1, np.nan)

# --- CH07: estado civil Ns/Nr ---
df_2005['CH07'] = df_2005['CH07'].replace(9, np.nan)
df_2025['CH07'] = df_2025['CH07'].replace(9, np.nan)

# --- CH08: cobertura médica Ns/Nr (9 = Ns/Nr; 123 es válido) ---
df_2005['CH08'] = df_2005['CH08'].replace(9, np.nan)
df_2025['CH08'] = df_2025['CH08'].replace(9, np.nan)

# --- NIVEL_ED: nivel educativo Ns/Nr ---
df_2005['NIVEL_ED'] = df_2005['NIVEL_ED'].replace(9, np.nan)
df_2025['NIVEL_ED'] = df_2025['NIVEL_ED'].replace(9, np.nan)

# --- CAT_OCUP: categoría ocupacional Ns/Nr ---
df_2005['CAT_OCUP'] = df_2005['CAT_OCUP'].replace(9, np.nan)
df_2025['CAT_OCUP'] = df_2025['CAT_OCUP'].replace(9, np.nan)

# --- PP04A: tipo de empresa (0 = no aplica, 9 = Ns/Nr) ---
df_2005['PP04A'] = df_2005['PP04A'].replace({0: np.nan, 9: np.nan})
df_2025['PP04A'] = df_2025['PP04A'].replace({0: np.nan, 9: np.nan})

# --- P21: ingreso ocupación principal ---
# 2005: no había -9 según diccionario, pero por las dudas limpiamos negativos
# 2025: -9 = no respuesta (confirmado en diccionario)
df_2005.loc[df_2005['P21'] < 0, 'P21'] = np.nan
df_2025.loc[df_2025['P21'] < 0, 'P21'] = np.nan

# --- IPCF: ingreso per cápita familiar ---
# Mismo criterio que P21
df_2005.loc[df_2005['IPCF'] < 0, 'IPCF'] = np.nan
df_2025.loc[df_2025['IPCF'] < 0, 'IPCF'] = np.nan

# --- PP06C y PP06D: ingresos de independientes ---
# -7 = no tenía esa ocupación, -8 = sin ingresos ese mes, -9 = no respuesta
for col in ['PP06C', 'PP06D']:
    for df in [df_2005, df_2025]:
        if col in df.columns:
            df[col] = df[col].replace({-7: np.nan, -8: np.nan, -9: np.nan})

# --- EMPLEO: formalidad laboral (solo existe en 2025; en 2005 ya es todo NaN) ---
if 'EMPLEO' in df_2025.columns:
    df_2025['EMPLEO'] = df_2025['EMPLEO'].replace(9, np.nan)

# --- Regla general: 9/99/999/9999 = Ns/Nr en variables categóricas de 1 dígito ---
# Las variables de ingresos (montos) son la excepción – ya tratadas arriba.
# Aplicar con criterio: solo donde el máximo valor válido lo permite.
```

Figure 12: *Captura 3.*

Consulta 2:




Figure 13: *Captura 4.*




Figure 14: *Captura 5.*

```
python

# =====
# ARMONIZACIÓN DE FORMATOS
# =====

# --- PROBLEMA 1: Variables de ingresos con -9 sin limpiar en 2025 ---
vars_ingreso_extra = [
    'PP08D1', 'PP08F1', 'PP08F2', 'PP08J1', 'PP08J2', 'PP08J3',
    'TOT_P12', 'P47T', 'T_VI',
    'V3_M', 'V4_M', 'V8_M', 'V9_M', 'V10_M', 'V12_M', 'V18_M'
]

for col in vars_ingreso_extra:
    if col in df_2025.columns:
        df_2025.loc[df_2025[col] == -9, col] = np.nan

print("[1] -9 en variables de ingreso → NaN (2025)")

# --- PROBLEMA 2: Variables de código string vs float ---
def normalizar_codigo(serie):
    """Convierte string o float a string entero limpio. NaN se preserva."""
    def _conv(x):
        if pd.isna(x):
            return np.nan
        try:
            val = str(x).strip()
            if val == '' or val in ('nan', 'None'):
                return np.nan
            return str(int(float(val)))
        except:
            return np.nan
    return serie.apply(_conv)

vars_codigo = [
    'CH14', 'CH15_COD', 'CH16_COD',
    'PP04B_COD', 'PP04D_COD', 'PP11B_COD', 'PP11D_COD'
]
```

Figure 15: *Captura 6.*


```

for col in vars_codigo:
    if col in df_2005.columns:
        df_2005[col] = normalizar_codigo(df_2005[col])
    if col in df_2025.columns:
        df_2025[col] = normalizar_codigo(df_2025[col])

print("[2] Variables de código normalizadas a string entero limpio")

# --- PROBLEMA 3: Variables de deciles con padding inconsistente ---
vars_deciles = [
    'DECOCUR', 'IDECOCUR', 'RDECOCUR', 'GDECOCUR', 'PDECOCUR', 'ADECOCUR',
    'DECINDR', 'IDECINDR', 'RDECINDR', 'GDECINDR', 'PDECINDR', 'ADECINDR',
    'DECIFR', 'IDECIFR', 'RDECIFR', 'GDECIFR', 'PDECIFR', 'ADECIFR',
    'DECCFR', 'IDEC CFR', 'RDECCFR', 'GDECCFR', 'PDECCFR', 'ADECCFR'
]

for col in vars_deciles:
    if col in df_2005.columns:
        df_2005[col] = normalizar_codigo(df_2005[col])
    if col in df_2025.columns:
        df_2025[col] = normalizar_codigo(df_2025[col])

print("[3] Variables de deciles normalizadas")

# --- VERIFICACIÓN ---
print("\nVerificación post-armonización:")
for col in ['CH14', 'DECOCUR', 'PP04B_COD']:
    v05 = set(df_2005[col].dropna().unique()) if col in df_2005.columns else set()
    v25 = set(df_2025[col].dropna().unique()) if col in df_2025.columns else set()
    comunes = v05 & v25
    print(f" {col}: {len(comunes)} valores en común entre bases")

```



Figure 16: *Captura 7.*

Consulta 3:




Figure 17: *Captura 8.*




Figure 18: *Captura 9.*




Figure 19: *Captura 10.*

1. **INTENSI** — Los códigos cambiaron completamente de significado:

Concepto	Código 2005	Código 2025
Subocupado horario (demandante + no demandante)	1 y 2	1
Ocupado pleno	3	2
Sobreocupado	4	3
No trabajó en la semana	5	4
Ns/Nr	9	9

Si no se corrige, en tu dataframe concatenado el código 2 mezcla "subocupados no demandantes" (2005) con "ocupados plenos" (2025).

2. **PP04G** — En 2005 el código 1 agrupaba "local/oficina/chacra/vivienda con lugar exclusivo". En 2025 eso se abrió en 11, 12 y 13. No se puede desagregar el viejo 1, así que lo mapeamos a 11 (la categoría más frecuente).

3. **PP07E** — En 2005 existía 1 = plan de empleo. En 2025 esa opción ya no existe (se removi6). Hay que mapearlo a NaN o dejarlo como categoría residual.

4. **PP11M** — Ídem: en 2005 existía 1 = plan de empleo, eliminado en 2025.

5. **PP11L1** — ¡La pregunta cambi6 por completo! En 2005 preguntaba si el trabajo era changa o permanente; en 2025 pregunta si cobraba un plan social. No son comparables, así que conviene marcar los datos de 2005 como NaN para esta variable (o renombrarla).

Acá va el bloque de código completo para agr ↓ después de la limpieza de NaN y antes del `pd.concat`:

Figure 20: *Captura 11.*

```
python

# =====
# ARMONIZACIÓN DE CODIFICACIÓN ENTRE 2005 Y 2025
# =====

# --- INTENSI: recodificar 2005 al esquema de 2025 ---
# 2005: 1=SubocDemandante, 2=SubocNoDemandante, 3=OcupPleno, 4=Sobreocupado, 5=NoTra
# 2025: 1=Subocupado, 2=OcupPleno, 3=Sobreocupado, 4=NoTrabajó, 9=Ns
# Se fusionan las categorías 1 y 2 de 2005 (ambas subocupación) en la categoría 1 de
intensi_map_2005 = {
    1: 1, # Subocupado demandante → Subocupado
    2: 1, # Subocupado no demandante → Subocupado
    3: 2, # Ocupado pleno → Ocupado pleno
    4: 3, # Sobreocupado → Sobreocupado
    5: 4, # No trabajó en la semana → No trabajó en la semana
    9: 9, # Ns/Nr → Ns/Nr
    0: 0 # No corresponde → No corresponde
}
df_2005['INTENSI'] = df_2005['INTENSI'].map(intensi_map_2005)
print("[4] INTENSI recodificado de 2005 al esquema 2025")

# --- PP04G: recodificar 2005 al esquema de 2025 ---
# En 2005, código 1 = "local/oficina/establecimiento/negocio/taller/chacra/finca" (t
# En 2025, se desagregó en: 11=local/oficina/taller, 12=vivienda con lugar exclusivo
# Como no es posible desagregar el viejo código 1, se mapea a 11 (la subcategoría má
# Los demás códigos (2-10) son idénticos.
df_2005.loc[df_2005['PP04G'] == 1, 'PP04G'] = 11
print("[5] PP04G código 1 (2005) → 11 (esquema 2025)")
```

Figure 21: *Captura 12.*

```
# --- PP07E: en 2005 existía 1="plan de empleo", eliminado en 2025 ---
# En 2025 solo existen 2=período de prueba, 3=beca/pasantía, 4=ninguno.
# Opciones: (a) dejar el 1 como está (categoría exclusiva de 2005),
#           (b) recodificarlo a NaN.
# Elegimos (a) para no perder información; pero si se necesita comparabilidad estricta
# Descomentar la línea siguiente para opción (b):
# df_2005.loc[df_2005['PP07E'] == 1, 'PP07E'] = np.nan
print("[6] PP07E: código 1 (plan de empleo) solo existe en 2005 - sin cambio")

# --- PP11M: en 2005 existía 1="plan de empleo", eliminado en 2025 ---
# Misma situación que PP07E.
# Descomentar para convertir a NaN si se desea comparabilidad estricta:
# df_2005.loc[df_2005['PP11M'] == 1, 'PP11M'] = np.nan
print("[7] PP11M: código 1 (plan de empleo) solo existe en 2005 - sin cambio")

# --- PP11L1: pregunta diferente entre años ---
# 2005: "¿Ese trabajo era... 1=changa/transitorio, 2=permanente, 3=Ns/Nr?"
# 2025: "¿Cobraba algún plan? 1=Sí, 2=No"
# NO SON COMPARABLES. Se recodifica 2005 a NaN para evitar confusión.
df_2005['PP11L1'] = np.nan
print("[8] PP11L1: pregunta incompatible entre años → NaN en 2005")

# --- Verificación final ---
print("\nVerificación post-armonización de codificación:")
for col in ['INTENSI', 'PP04G']:
    v05 = set(df_2005[col].dropna().unique())
    v25 = set(df_2025[col].dropna().unique())
    print(f"  {col}:")
    print(f"    2005 (recodificado): {sorted(v05)}")
    print(f"    2025: {sorted(v25)}")
```

En resumen: el problema que más impactaría en tus análisis no era texto vs. numérico (eso ya lo resolvía `convert_categoricals=False`), sino que `INTENSI` tenía códigos que significaban cosas distintas entre años. Sin esta corrección, cualquier análisis que use intensidad ocupacional mezclaría categorías incompatibles.

Figure 22: *Captura 13.*

2. Reflexión

Nuevamente, tal como lo fue en el caso del trabajo anterior, la IA nos fue útil con cuestiones de funciones específicas relacionadas al código. En este contexto, la IA fue extremadamente útil para guiarnos en la dirección correcta. En particular, nos ayudó con cuestiones de errores técnicos en el código para que pudiéramos corregirlos, y para poder entender cuáles eran los errores que estábamos cometiendo. En este trabajo, sin embargo, sentimos que tuvimos más necesidad de recurrir a ayuda de la IA para resolver problemas con la limpieza de datos y unificación de bases.

3. Realización

En total, diríamos que este trabajo nos llevó menos tiempo que el anterior. Aproximadamente, estuvimos una tarde y un día entero resolviendo el trabajo.