



Universidad de
San Andrés

Big Data

Trabajo Práctico 5

Otoño 2026

Integrantes:

Constanza María Efkhanian
Julián Fabrizio Notario
María Florencia Pascale

Fecha de entrega: 12 de junio de 2026

A. Árboles

1. Construimos una grilla de 40 valores de `ccp_alpha` a partir del path de poda del árbol completo. Para cada valor, se computó el error de clasificación promedio con 10-fold cross-validation. En el gráfico se ve cómo el error decrece al aumentar `ccp_alpha`. El árbol resultante tiene 32 nodos terminales y profundidad 10, con error en train de 0.066 y error en test de 0.113.




Figure 1: Error de clasificación en función de `ccp_alpha` – 10-fold CV

2. Panel A: La primera partición usa el ingreso (CH08), separando trabajadores de bajos ingresos del resto. En la rama de ingresos altos, se distingue a los asalariados formales de los cuentapropistas y trabajadores familiares. Dentro de nuestra base de datos y nuestras variables elegidas, el ingreso y el tipo de relación laboral son los principales discriminantes en cuanto a la informalidad.

Panel B: La ocupación y el ingreso concentran el 78% de la reducción de la impureza. Las otras 19 variables tienen importancia nula, lo que es consistente con los resultados de LASSO.




Figure 2: Panel A – Árbol de decisión podado




Figure 3: Panel B – Importancia de los predictores

B. Comparación entre métodos

3.

Modelo	1Acc	AUC	Sensibilidad	Especificidad
Logit sin penalidad	0.112	0.920	0.716	0.952
Logit LASSO	0.112	0.920	0.716	0.952
Logit Ridge	0.111	0.920	0.720	0.952
CART	0.113	0.907	0.758	0.935
KNN	0.171	0.846	0.502	0.951

Table 1: Comparación de modelos – EPH 2025




Figure 4: Matrices de confusión – umbral $p > 0.5$




Figure 5: Curvas ROC – Comparación de modelos

Los tres modelos logísticos tienen diferencias mínimas, lo que muestra que la regularización no aporta mejoras sustanciales en este caso. CART tiene AUC menor pero mayor sensibilidad, es decir, detecta más informales a costa de más falsos positivos. KNN tiene la peor performance en todas las dimensiones.

El logit tiene la mayor interpretabilidad y performance, mientras que CART es visualmente comunicable pero con peor performance. No vemos ventajas claras del método no lineal.

4. Para asignar recursos escasos, el error más relevante es el falso negativo. CART, con umbral 0.5, tiene la mayor sensibilidad de 0.758 y mejor F1 de 0.785, lo que lo hace el mejor modelo para este objetivo. Sin embargo, bajando el umbral del Logit Ridge a 0.3, se obtiene una sensibilidad de 0.841, superior a la de los demás modelos. La decisión depende de qué se prefiera: excluir un informal o incluir un formal.






Figure 6: Curvas Precisión-Recall – Comparación de modelos

C. Herramientas de IA y reflexión final

1.

A continuación, se detalla el uso de la IA para la elaboración de este trabajo. Vale la pena aclarar que únicamente utilizamos Claude.



2.

Nuevamente, la inteligencia artificial nos fue útil en la corrección de código y en el uso de diversos comandos vistos en clase. Por otro lado, para la interpretación de los resultados obtenidos en los incisos anteriores optamos por no usar la IA, y confiamos en nuestros conocimientos teóricos adquiridos en la materia.

3.

Tal como fue previsto, el tiempo de realización de este trabajo fue el más corto de todos, llevándonos aproximadamente 4 horas en terminarlo.